revisão – Revisão de Caches

- Localidade Temporal
  - bloco será referenciado novamente no futuro próximo
- Localidade Espacial
  - blocos vizinhos serão referenciados no futuro próximo
- Taxa de Acertos = núm_acertos / núm_referências
  - Taxa de Faltas = 1 - Taxa_de_acertos
- TMAM = TempoDeAcerto + (TaxaDeFaltas × PenalidadePorFalta)
  melhorar um termo geralmente piora outro/s
- 3 Cs: faltas compulsórias, por conflitos, por capacidade
  - compulsórias: são compulsórias...
  - conflitos: ender ≠s mapeiam no mesmo bloco ↑associatividade
  - capacidade: |conj de dados| > |cache|; ↑tamanho

Hierarquia de Memória

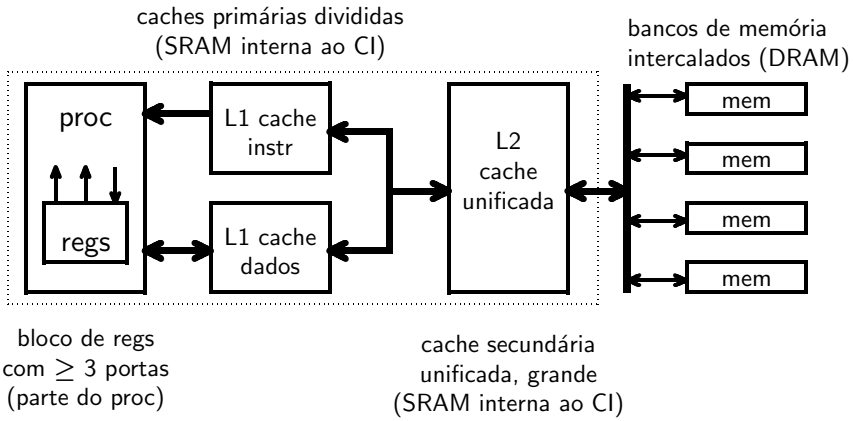

$$T_{\text{mam}} = T_{L1} + F_{L1} \cdot [\, T_{L2} + F_{L2} \cdot (T_m + F_m \cdot ?) \,]$$

Implementação da Escrita

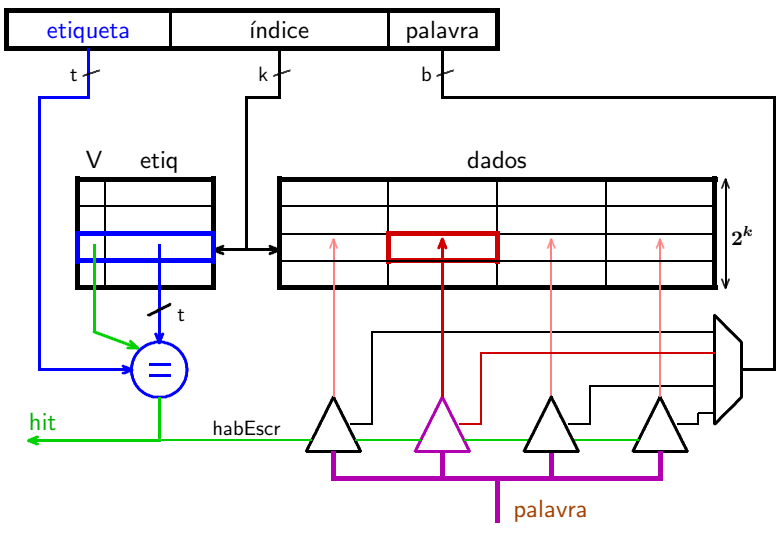

Políticas de escrita

Escrita forçada (*write-through*)
- propaga escrita até memória
- escritas completam na velocidade da memória

Escrita preguiçosa (*write-back*)
- acumula escritas na cache
  - bit `sujo` para lembrar
- escritas completam na velocidade da cache
- falta em leitura pode custar
  - escrita da vítima se sujo
  - falta ⟶ escrita+leitura

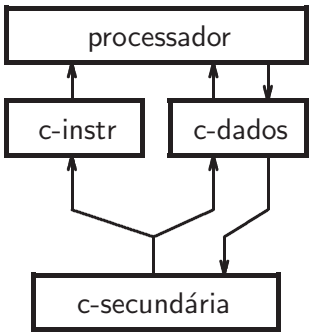

Políticas de escrita – Escrita Forçada

Escritas completam na velocidade da memória;

cada escrita é propagada até a memória
⟶ memória sempre contém cópia atualizada

temporização: compara-etiqueta || escreve-dado — um ciclo
- se acerto ⟶ tudo pronto
- se falta ⟶ sobreescreve bloco antigo (ok, memória atualizada)

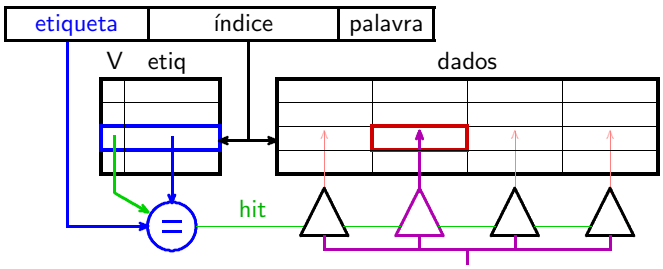

Políticas de escrita – Escrita Preguiçosa

Escritas completam na velocidade da cache;

acumula escritas na cache ⟶ a cada escrita, bit `sujo` é ligado

falta: ao substituir, bloco vítima sujo enviado para atualizar memória
- falta na leitura pode causar escrita se bloco vítima está sujo

temporização: compara-etiqueta ; escreve-dado — dois ciclos
- se acerto ⟶ só escreve no próximo ciclo
- se falta ⟶ não pode sobreescrever sem atualizar memória

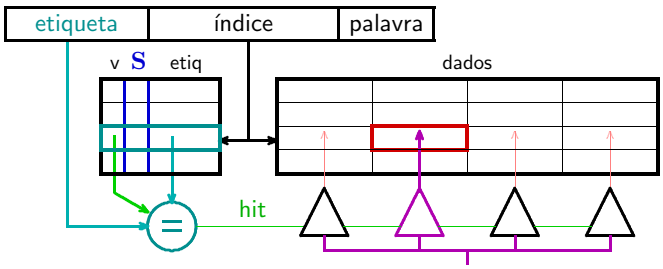

Políticas de escrita – Escrita Preguiçosa

Pode reduzir tempo de escrita com um store buffer

temporização: compara-etiqueta || escreve-dado-no-store buffer
atualiza cache no próximo ciclo vago, em acerto ou em falta

Usa dois buffers:
store buffer "antes da cache" para minimizar tempo de escrita
write buffer "depois da cache" para minimizar tempo de substituição

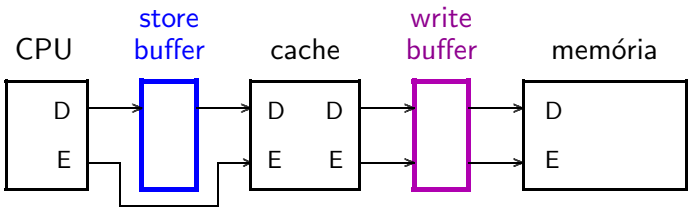

Implementação de Escrita Forçada

A cada instrução `sw $r, desloc($i)`
propaga conteúdo de `$r` até memória
⟶ `sw` custa referência à memória (10-100 ciclos)
10% das referências são escritas
⟶ muito tráfego entre cache e memória
MAS cache e memória sempre consistentes

```
for (i=0; i<100; i++)    /* i⟶100×{lw;add;sw} */
                         /* 100 acessos ao segundo nível */
   res[i] = vetor[i] * const;
```


Implementação de Escrita Preguiçosa

A cada instrução `sw $r, desloc($i)`
atualiza bloco na cache e marca-o como `sujo`
⟶ `sw` custa referência à cache (se acerto, 2 ciclos)
10% das referências são escritas
⟶ pouco tráfego entre cache e memória
MAS cache e memória ficam **IN**consistentes
falta de leitura pode custar *escrita* ; *busca*

```
for (i=0; i<100; i++)    /* i⟶100×{lw;add;sw} */
                         /* 2 acessos a segundo nível */
   res[i] = vetor[i] * const;
```

O que fazer quando ocorre uma falta na escrita?

- Aloca espaço na escrita *write-allocate*
  - ⋆ espaço é alocado na cache para bloco faltante, e então é atualizado
  - ⋆ se uma palavra no bloco foi atualizada, outras também o serão...
  - ⋆ se cache com escrita preguiçosa, falta provoca até duas transações:
    1) se bloco está sujo, expurga-o
    2) carrega bloco faltante
- Não aloca espaço na escrita *no-write-allocate*
  - ⋆ não é alocado espaço na cache para bloco faltante
  - ⋆ se não ocorreu falta de leitura, bloco pode não ser necessário...
  - ⋆ bloco faltante é atualizado diretamente na memória
  - ⋆ fila de escrita é imprescindível
- Combinações comuns
  - ⋆ escrita forçada & não-alocação de espaço (na falta) *no-fetch-on-write*
  - ⋆ escrita preguiçosa & alocação de espaço (na falta) *fetch-on-write*

Fila de escrita I

Referências de escrita bloqueiam processador até que acesso ao nível mais baixo da hierarquia complete

10% das referências são escritas;
escritas na cache secundária custam $\approx$ 10 ciclos
$T_{\text{mem}} = 0.9 * 1 + 0.1 * 10 = 1.9$ ciclos

solução: fila de escrita *write-buffer*
para desacoplar velocidade do processador da velocidade da memória

* imprescindível com escrita forçada
* com escrita forçada, fila tem largura $\geq$ uma palavra
* com escrita preguiçosa, fila tem largura de um bloco porque todo o bloco é marcado sujo e precisa ser atualizado na memória

Fila de escrita II

Fila reduz tempo médio da referência de escrita:
escrever na interface da fila custa 1 ciclo

cada elemento da fila contém um par <endereço, bloco*>
* palavra$^+$ (forçada), bloco (preguiçosa)

controlador de cache efetua atualização da L2/memória

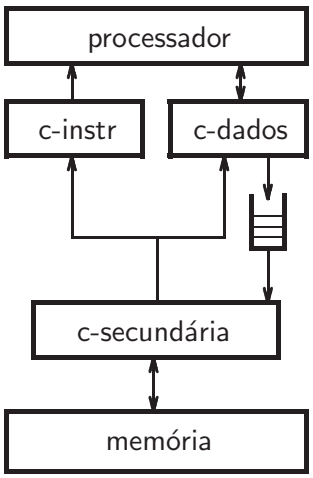

Fila de escrita III

- Processador executa `sw $5,24($8)`
  - em MEM, processador insere na fila par <(24+$8), $5> ← EF
  - se há espaço na fila, escrita completa em um ciclo
  - senão, processador bloqueia até abrir espaço na fila, enquanto escrita na cabeça da fila é propagada até L2
- Fila tem capacidade para 1-16 registros
  fila enche na entrada de funções com muitos parâmetros...

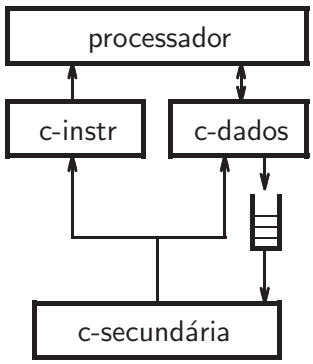

Desempenho de Caches I

TempoCPU =
(ciclosEmExecução + ciclosParados) × duraçãoDoCiclo

ciclosParados =
(ciclosDeLeituraParados + ciclosDeEscritaParados)

ciclosDeLeituraParados =
leituras/programa × taxaFaltasLeitura × penalidadeLeitura

ciclosDeEscritaParados =
escritas/programa × taxaFaltasEscrita × penalidadeEscrita
+ esperaNaFilaDeEscrita

Desempenho de Caches II

TempoCPU = (ciclosEmExecução + ciclosParadosPorMemória)
× duraçãoDoCiclo

Combinando escritas e leituras numa única taxa:

ciclosParadosPorMemória
= referências/programa × taxaDeFaltas × penalidadePorFalta
= instruções/programa × faltas/instrução × penalidadePorFalta

Desempenho de Caches – exemplos

Exemplo 1: GCC em máquina com memória perfeita atinge CPI=2.0. Taxa de faltas em instruções é 5%; taxa de faltas em dados é 10%; penalidade por falta é 12 ciclos; 33% das instruções são LDs e STs. Determine relação entre velocidades com memória perfeita e real.

ciclosPerdidosInstruções = IC * 5%*12 = 0.6 IC
ciclosPerdidosDados = IC * 33% * 10%*12 = 0.4 IC

Número total de ciclos perdidos em faltas = 0.6+0.4 IC = 1.0 IC
$\text{CPI}_{\text{real}} = 2.0 + 1.0 = 3.0$

tempoCPUmemReal = IC * CPI_{real} * ciclo = 3.0 * IC * ciclo

tempoCPUmemIdeal = IC * $\text{CPI}_{\text{ideal}}$ * ciclo = 2.0 * IC * ciclo

3.0 / 2.0 = 1.5

Desempenho de Caches – exemplos

Exemplo 2: GCC em máquina com memória perfeita atinge CPI=2.0. Taxa de faltas em instruções é 5%; taxa de faltas em dados é 10%; penalidade por falta é 12 ciclos; 33% das instruções são LDs e STs. Determine relação entre velocidades com memória perfeita e real.

Número total de ciclos perdidos em faltas =
IC*(5%*12 + 0.33 * 10%*12) = 1.0 IC; $\text{CPI}_{\text{lenta}} = 2.0+1.0 = 3.0$

Nova CPU com relógio 2 vezes mais rápido, penalidade é **24** ciclos.

Número total de ciclos perdidos em faltas =
IC*(5%*24 + 0.33 * 10%*24) = 2.0 IC; $\text{CPI}_{\text{rapida}} = 2.0+2.0 = 4.0$

Ganho = $\text{tempo}_{\text{lenta}}$ / $\text{tempo}_{\text{rapida}}$ =
(IC * $\text{CPI}_{\text{lenta}}$ * ciclo) / (IC * $\text{CPI}_{\text{rapida}}$ * ciclo/2) =
(3.0 / (4.0*1/2)) = 3/2 = $\mathbf{1.5 \ll 2.0}$!!

resumo – Caches

- Localidade
  - ⋆ Temporal: bloco será referenciado novamente no futuro próximo
  - ⋆ Espacial: blocos vizinhos serão referenciados no futuro próximo
- 3 Cs: faltas compulsórias, por conflitos, por capacidade
- Políticas de escrita
  - ⋆ escrita forçada, escrita preguiçosa
  - ⋆ fila de escrita desacopla velocidades da CPU daquela da L2/memória
  - ⋆ nas faltas em escrita: aloca espaço, não-aloca espaço
- TempoCPU = (ciclosEmExecução + ciclosParadosMemória) × duraçãoDoCiclo
  ciclosParadosPorMemória
  = referências/programa × taxaDeFaltas × penalidadePorFalta
  = instruções/programa × faltas/instrução × penalidadePorFalta